

李乐岩

leyanpower@gmail.com | 3073751449@qq.com | +86 18805506898 | github.com/lionlepower | leyan-li.com
爱丁堡大学 University of Edinburgh 英国 | 2025.09 – 2026.12 (预计) 高性能计算与数据科学 硕士
利物浦大学 University of Liverpool 英国 / 西交利物浦大学 | 2021.09 – 2025.06 计算机科学 本科 (2+2) , 一等荣誉学位

技术能力

编程语言: C / C++、Python、Bash、SQL

深度学习与大模型: PyTorch、NumPy、pandas; 多智能体 actor-critic 训练与不收敛根因诊断; LLM function calling / tool schema 设计、离线评测集与消融实验、最小 RAG; 了解上下文压缩、并行处理与 LangChain / LangGraph 等框架

后端与服务化: FastAPI + Pydantic、SQLite / MySQL (索引、事务与查询优化)、REST / HTTP、JSON Lines 结构化日志; 异常到 HTTP 语义的映射 (依赖未就绪 503、参数非法 422); 了解限流、幂等性、Redis 缓存场景与 TTL、Docker

工程与工具链: Linux、Git、pytest、GitHub Actions CI; 习惯把工作做成可复现管线: 参数化脚本 → 基于内容的输入校验 → 聚合与回归测试, 把关键数值锁进测试以防结论漂移

并行与分布式: MPI、OpenMP、hybrid MPI+OpenMP、PETSc、Slurm、numactl / hwloc / lscpu; strong / weak scaling、parallel efficiency 与饱和点判定; halo exchange、CG global reduction (allreduce) 等集合通信开销与 surface-to-volume ratio 对通信暴露的影响

项目经历

面向 ARCHER2 超算上 PETSc benchmark 数据的 Agent 式性能分析系统

lionlepower/HPC_Agent

| Python · SQLite · FastAPI · Pydantic · OpenAI SDK (function calling) · pytest · RAG

项目描述: 把英国国家超算 ARCHER2 上真实的 PETSc benchmark 结果结构化 SQLite, 把性能分析任务封装为确定性工具: 让 LLM 只负责「选哪个工具、参数是什么」, 数值一律由确定性代码算, 从而让 Agent 的正确性变成可评测量。

- **分层架构与同构契约:** 为了让规则 router 与 LLM tool call 能同尺比较, 两者输出严格同构 (intent + 参数); 导入 / 指标 / 工具 / 检索 / 路由 / 可观测六层, CLI 与 FastAPI 为互不依赖的进程边界; 共用同一套评测集打分, 切换只改一行 dispatch。
- **LLM function calling 与防御式解析:** tool schema 的 description 写明工具边界, unknowns 刻意设为可选——省略参数即「追问」、不调用工具即「拒答」; 未调用工具、幻觉工具名、arguments 非合法 JSON 三类异常统一收敛为显式 unknown, 绝不猜参数, 以避免「静默算错」; API 失败向上抛出而非回退规则 router, 以免污染评测。
- **评测机制与消融结论:** 自建 30 问五类中文评测集 (正常 / 追问 / 拒答 / 数字陷阱 / 对抗题), 期望值是 tool call 而非答案文本, harness 对 router 实现无知; 规则 83.3%、LLM 100%, 消融显示同一模型去掉 system prompt 只有 63.3%——准确率主要由工具说明书与策略 prompt 决定。局限如实标注: 题量 30、单模型、单次运行、出题人即作者。
- **可观测性:** 为了让路由出错时能定位到具体哪一步, trace_id 贯穿的 JSON Lines 事件流把每次 ask 落成 ask_start / route_result / tool_call / tool_result / answer 5 个事件, 可完整回放一次执行; 脱敏收敛在单一出口点并由扫描测试强制。
- **自动化测试覆盖异常边界:** LLM 客户端经依赖注入换成 FakeLLM, 229 项测试全量离线、不需要 API key, CI 每次 push 复跑; 各层合同钉死——三类 LLM 异常各有用例, FastAPI 的 POST /ask 把非法 router 拦为 422、缺 key 映射 503。
- **词法检索而非向量检索 (最小 RAG):** 为了不引入 embedding 模型与向量库、也不动评测口径, 用 IDF 加权词法检索 (纯标准库): 离线、确定性、每条命中可按 idf 分数解释; 无命中即不注入, 未开启时 messages 与评测时逐字节一致 (测试锁死); 代价是同义改写检索不到。

ARCHER2 超算上 4,096 核的 PETSc 布局对照实验——上一项目的数据来源

lionlepower/HPC_PETSC_Benchmark

| C · PETSc · MPI · OpenMP · Slurm · Linaro MAP · Python / pandas · GitHub Actions (硕士毕业论文)

项目描述: 在英国国家超算 ARCHER2 (AMD EPYC 7742、128 核/节点, Slingshot 互连) 上研究一个受约束的配置问题: 总核数固定时, MPI rank 数与每 rank 的 OpenMP 线程数怎么切分——真实作业里这两个值几乎都由提交脚本默认值决定, 默认值的代价很少被量化。负载 2D/3D stencil + CG+GAMG, 5M-165M unknowns, 四种满节点布局 128×1 / 64×2 / 32×4 / 16×8。

- **自建可累加的同步指标:** -log_view 零插桩、覆盖 264 个 weak-scaling run, 但事件嵌套使叶子事件直接相加达 KSPSolve 的 116–372%; 由于 halo 交换与全局归约在互不相交的调用路径上, 取二者之和定义「同步暴露占比」(MAP 扰动运行时间, 只读占比排序)。32 节点上从 flat MPI 的 48.2% 降到 16×8 的 26.4%, 使「为什么更快」可逐点度量而非事后解释。
- **性能结论 (摘要):** weak scaling 上 2D 最佳布局 64×2 (165M / 32 节点 794.8M equations/s, 比 flat MPI 高 13.1%)、3D 最佳 32×4 (最大增益 33.2%); fixed-20M strong scaling 上 2D 达 29.83× 加速 / 93.2% 累积效率, 3D 的 16×8 比 flat MPI 快 3.81×。最佳布局随维度、规模与每核工作量改变, Linaro MAP 定位其机理为 MPI 通信暴露 (46.7%→6.2%) 与 OpenMP 空转等待 (48.3%→76.5%) 的交点。
- **对算力成本的含义:** 只改提交脚本的两个默认值、不改代码不加节点: 同一作业的节点时在 2D weak 最大点少用 11.6%、3D 最佳点少用 24.9%, 3D fixed-20M 32 节点上降到 flat MPI 的 26%; 交付的是「先量再定默认值」的方法而非固定配置。

多智能体 Actor-Critic 方法中的价值函数分解研究

lionlepower/MARL_VALUE_FACTORISATION

| Python · PyTorch · PyMARL · MAPPO · VDN · QMIX · CTDE · PPO · PettingZoo / MPE2 (本科毕业设计)

项目描述: 在 MAPPO 的 critic 上分别接入 VDN 加性分解与 QMIX 单调 mixing 做单变量对照——三个变体共用同一套 runner / buffer / shared RNN actor 与全部 PPO 超参, 差异只在 critic 分支。

- **反直觉结论与根因诊断:** 表达能力更强的 critic 没有赢——稀疏奖励的 Predator-Prey (300k steps) 上加性分解唯一学到正回报 (≈150), 单体 critic 始终为负, QMIX 的 critic loss 起手即 5.4×10^4 、200k 步后二次发散。根因是 MAPPO-QMIX 的 TD 目标沿用 value-based 的 $\max_a Q_t$ 而 actor 是 on-policy, td_error 并非合法 advantage 而是系统性乐观; 非单调 mixer 的持续梯度爆炸作为负结果写进论文, 归结为结构性归纳偏置是 actor-critic 稳定训练的前提。

论文发表： Li, Leyan. Convolutional Neural Networks Based Medical Image Analysis. International Conference on Engineering Management, Information Technology and Intelligence, EMITI 2024.